

Algorithmes efficaces pour le contrôle et l'apprentissage par renforcement

CJC-MA 2021, Palaiseau

Eloïse BERTHIER

Jeudi 28 octobre 2021



Plan

1 Introduction

2 Discrétisation de problèmes à espace d'état continu

3 Contrôle optimal lisse basé sur des observations

Contrôle optimal & Apprentissage par renforcement

$$\min_{u(\cdot)} \int_0^T L(x(t), u(t)) dt$$
$$\dot{x}(t) = f(x(t), u(t)).$$


$$\max_{a_0, \dots, a_{n-1}} \mathbb{E} \left[\sum_{t=1}^n r_t \right]$$

$$s_{t+1} \sim P(s_t, a_t)$$

$$r_{t+1} \sim R(s_t, a_t).$$



Motivation : Application à la robotique



France 2030 : Emmanuel Macron annonce 800 millions d'euros pour développer le secteur de la robotique

Publié le 25/10/2021 15:13

Motivation : Application à la robotique

Contrôler un robot présente plusieurs difficultés :

- Les systèmes sont en **dimension** (relativement) grande
 ⇒ on ne peut espérer résoudre exactement les problèmes de contrôle optimal (*malédiction de la dimension*).
- Les systèmes dynamiques sont **non-linéaires**
 ⇒ pas d'utilisation directe des outils du contrôle linéaire.
- Le **modèle** du système est imparfait
 ⇒ une solution exacte aurait peu d'intérêt.
- Certains calculs doivent être faits en **temps réel**, ou sur des **systèmes embarqués**
 ⇒ puissance et temps de calcul disponibles sont limités.

Plan

1 Introduction

2 Discrétisation de problèmes à espace d'état continu

3 Contrôle optimal lisse basé sur des observations

Idée générale

On considère un **Processus de Décision Markovien** (MDP) à espace d'état continu (temps et contrôle discrets). On cherche à le **discréteriser** en un MDP fini (état discret), par exemple pour approximer la fonction valeur avec l'algorithme de value iteration.

Problème : Une discréétisation naïve n'a pas de notion de proximité spatiale. Pour capturer la dynamique, pour une discréétisation de pas ε , la taille en mémoire $O(\varepsilon^{-d})$ explose avec la dimension d .

On suit l'approche de [McE03, AGL08], pour calculer une approximation max-plus linéaire de la fonction valeur¹.

1. E. Berthier, F. Bach. Max-Plus Linear Approximations for Deterministic Continuous-State Markov Decision Processes. *IEEE Control Systems Letters*, 4(3) :767-772, 2020.

Processus de décision Markovien

On considère un MDP déterministe, à horizon infini, défini par :

- un **espace d'états** borné $\mathcal{S} \subset \mathbb{R}^d$,
- un **espace d'actions** \mathcal{A} fini,
- une **fonction de récompense** $r : \mathcal{S} \times \mathcal{A} \rightarrow [-R, R]$,
- une **dynamique** $\varphi(\cdot) : \mathcal{S} \times \mathcal{A} \rightarrow \mathcal{S}$,
- un **facteur d'actualisation** $0 \leq \gamma < 1$.

La **fonction valeur** $V^* : \mathcal{S} \rightarrow \mathbb{R}$ est la récompense cumulée actualisée maximale :

$$V^*(s) = \max_{\pi} \sum_{t=0}^{\infty} \gamma^t r_t, \quad s_0 = s.$$

Elle correspond à une **politique optimale** $\pi^* : \mathcal{S} \rightarrow \mathcal{A}$:

$$\pi^*(s) \in \operatorname{argmax}_{a \in \mathcal{A}} r(s, a) + \gamma V^*(\varphi_a(s)).$$

Value Iteration

L'algorithme de **value iteration** consiste à calculer V^* comme l'unique **point fixe** de l'opérateur de Bellman $T : \mathbb{R}^S \rightarrow \mathbb{R}^S$:

$$TV(s) := \max_{a \in \mathcal{A}} r(s, a) + \gamma V(\varphi_a(s)).$$

L'algorithme calcule itérativement $V_{k+1} = TV_k$, et converge linéairement vers V^* . Si \mathcal{S} est un ensemble fini, l'algorithme fait $O(|\mathcal{A}| \cdot |\mathcal{S}|)$ opérations, et stocke $O(|\mathcal{S}|)$ valeurs à chaque itération.

Propriétés max-plus de l'opérateur de Bellman

Le semi-anneau max-plus est défini par $(\mathbb{R} \cup \{-\infty\}, \oplus, \otimes)$, où \oplus représente l'opérateur maximum, et \otimes la somme usuelle.

La structure de l'opérateur de Bellman :

$$T : \mathbb{R}^{\mathcal{S}} \rightarrow \mathbb{R}^{\mathcal{S}}$$

$$TV(s) = \max_{a \in \mathcal{A}} r(s, a) + \gamma V(\varphi_a(s))$$

est naturellement **compatible** avec l'algèbre max-plus. T est max-plus additif et homogène :

$$T(V \oplus V') = T(\max\{V, V'\}) = \max\{TV, TV'\} = TV \oplus TV'$$

$$T(c \otimes V) = T(c + V) = \gamma c + TV = c^{\otimes \gamma} TV.$$

L'additivité n'est plus vérifiée pour des MDP stochastiques.

Approximation max-plus linéaire

Soit \mathcal{W} un dictionnaire de fonctions $w : \mathcal{S} \rightarrow \mathbb{R}$. On approxime V comme une combinaison **max-plus linéaire** de fonctions de \mathcal{W} :


$$V(s) = \bigoplus_{w \in \mathcal{W}} \alpha(w) \otimes w(s) = \max_{w \in \mathcal{W}} \alpha(w) + w(s).$$

Dictionnaires de fonctions :

- Lisses : $w(s) = -c\|s - s_0\|^2$
- Indicatrices : $w(s) = \begin{cases} 0 & \text{si } s \in A_w \\ -\infty & \text{sinon.} \end{cases}$
- ...

Les indicatrices permettent d'approximer V^* avec une fonction constante par morceaux (discrétisation).

Approximation max-plus linéaire




Exemple d'approximation max-plus linéaire avec indicatrices.

Max-plus value iteration


Pour calculer cette approximation : Max-plus value iteration.

Naive Discretization



Coarse Discretization




Max-Plus Discretization



Tight Discretization




Exemple numérique




Mountain MDP ($d = 2$).

Exemple numérique



Fonction valeur obtenue avec la max-plus value iteration.

Exemple numérique



On obtient une discréétisation plus compacte.

Plan

- 1 Introduction
- 2 Discrétisation de problèmes à espace d'état continu
- 3 Contrôle optimal lisse basé sur des observations

Idée générale

Constat : Les problèmes de contrôle optimal sont difficiles à résoudre numériquement, même pour des systèmes de dimension modeste.

On étend la méthode de [LHPT08] pour en calculer une approximation² :

- dans le cas des **problèmes lisses**,
- de façon “**black-box**” (à partir d’observations, sans gradients),
- qui peut passer à l’échelle en **grande dimension**.

2. E. Berthier, J. Carpentier, A. Rudi, F. Bach. Infinite-Dimensional Sums-of-Squares for Optimal Control. *Technical Report*, [\(hal-03377120\)](https://hal.archives-ouvertes.fr/hal-03377120/), 2021

Problème de contrôle optimal

On considère le problème à horizon fini, avec des espaces d'état et de contrôle compacts $\mathcal{X} \subset \mathbb{R}^d$ et $\mathcal{U} \subset \mathbb{R}^p$:

$$\begin{aligned} V^*(t_0, x_0) &= \inf_{u(\cdot)} \int_{t_0}^T L(t, x(t), u(t)) dt + M(x(T)) \\ \forall t \in [t_0, T], \quad &\dot{x}(t) = f(t, x(t), u(t)), \quad x(0) = x_0. \quad (\text{OCP}) \end{aligned}$$

Formulation faible du problème de contrôle

Sous certaines conditions le problème est équivalent à :

$$\begin{aligned} & \sup_{V \in C^1([0, T] \times \mathcal{X})} V(0, x_0) \\ & \forall (t, x, u), \frac{\partial V}{\partial t}(t, x) + L(t, x, u) + \nabla V(t, x)^\top f(t, x, u) \geq 0 \\ & \forall x, V(T, x) \leq M(x). \end{aligned} \tag{P}$$

On cherche V dans un espace de dimension fini \mathcal{F} paramétrisé par $\theta \in \mathbb{R}^m$. Si $V^* \in \mathcal{F}$, (P) est un programme linéaire, avec **un ensemble dense de contraintes** de la forme :

$$\forall (t, x, u), H(t, x, u) \geq 0.$$

Première idée : discrétisation naïve

Sous-échantillonner les contraintes donne une **relaxation** simple :

$$\begin{aligned} & \sup_{\theta \in \mathbb{R}^m} V_\theta(0, x_0) - \lambda_\theta \|\theta\|_2^2 \\ & \forall i \in I, \quad H(t^{(i)}, x^{(i)}, u^{(i)}) \geq 0. \end{aligned} \tag{LP}$$

Cette relaxation est connue dans le cas de l'**optimisation globale** :

$$\sup c \text{ s.t. } \forall y \in \mathbb{R}^p, g(y) - c \geq 0.$$

Le sous-échantillonnage équivaut à $\min g \simeq \min\{g(x_i)\}$. Il faut $O(\varepsilon^{-p})$ échantillons pour approximer $\min g$ avec précision ε .

Si $g \in C^s(\mathbb{R}^p)$ est lisse, ce taux peut être amélioré à $O(\varepsilon^{-p/s})$ en utilisant une représentation “sommes de carrés”.

Représentation de fonctions positives par sommes de carrés

On a un ensemble dense de contraintes :

$$\forall(t, x, u), \quad H(t, x, u) \geq 0.$$

Dans le cas polynomial : la méthode “moments - sommes de carrés” ou hiérarchie de Lasserre [Las10] consiste à représenter les polynômes positifs par une somme de carrés de polynômes :

$$p(x) = \sum_{k=1}^{\ell} p_k(x)^2 \geq 0.$$

Dans le cas lisse : une représentation similaire a été introduite récemment [MFBR20, RMFB20] pour représenter des fonctions positives dans un espace de Sobolev, en utilisant une méthode à noyaux.



Problème en dimension finie

Après sous-échantillonnage, la méthode conduit à un **programme SDP** de la forme :

$$\sup_{B \succcurlyeq 0, \theta \in \mathbb{R}^m} c^\top \theta - \lambda_\theta \|\theta\|_2^2 - \lambda \text{Tr}(B) + C$$

such that $\forall i \in \{1, \dots, n\}, b_i + a_i^\top \theta = (\Phi_i)^\top B \Phi_i.$ (KSOS)

Exemple numérique



Cas d'un problème LQR en dimension 2.

Conclusion

- On regarde des problèmes où on est confronté à la **“malédiction de la dimension”**.
- On cherche à faire le lien entre **contrôle optimal** et **apprentissage par renforcement** (discret et continu, model-based et model-free...).
- On cherche à **exploiter la structure** des problèmes de contrôle, comme c'était le cas des problèmes d'optimisation (lisse, fortement convexe...) et d'apprentissage (modèles linéaires...)

→ *Comment reconnaître les problèmes “faciles” en contrôle ?*

Références

-  Marianne Akian, Stéphane Gaubert, and Asma Lakhoua, *The max-plus finite element method for solving deterministic optimal control problems : basic properties and convergence analysis*, SIAM Journal on Control and Optimization **47** (2008), no. 2, 817–848.
-  Jean-Bernard Lasserre, *Moments, positive polynomials and their applications*, vol. 1, World Scientific, 2010.
-  Jean-Bernard Lasserre, Didier Henrion, Christophe Prieur, and Emmanuel Trélat, *Nonlinear optimal control via occupation measures and LMI-relaxations*, SIAM J. on Control and Optim. **47** (2008), no. 4, 1643–1666.
-  William M. McEneaney, *Max-plus eigenvector representations for solution of nonlinear H_∞ problems : basic concepts*, IEEE Transactions on Automatic Control **48** (2003), no. 7, 1150–1163.
-  Ulysse Marteau-Ferey, Francis Bach, and Alessandro Rudi, *Non-parametric models for non-negative functions*, Advances in Neural Information Processing Systems, 2020.
-  Alessandro Rudi, Ulysse Marteau-Ferey, and Francis Bach, *Finding global minima via kernel approximations*, Tech. Report 2012.11978, arXiv, 2020.